Cluster Analysis Tutorial

R 공개강좌

서울대학교 통계연구소

오늘 다룰 내용

- 1. K-means clustering
- 2. Partitioning Around Medoids (PAM) clustering
- 3. Hierarchical clustering

```
data_univ <- read.csv("data/University.csv", header=T)
head(data_univ)</pre>
```


```
SAT Top10 Accept SFRatio Expenses Grad
##
    University
## 1
       Harvard 14.00
                        91
                               14
                                        11
                                             39.525
                                                      97
## 2
     Princeton 13.75
                        91
                               14
                                        8
                                            30,220
                                                     95
## 3
          Yale 13.75
                        95
                               19
                                       11
                                            43.514
                                                     96
      Stanford 13.60
                        90
                               20
                                       12
                                            36.450
                                                     93
## 4
## 5
           MIT 13.80
                        94
                               30
                                       10
                                           34.870
                                                     91
          Duke 13.15
                                       12
                                            31.585
## 6
                        90
                               30
                                                     95
```

- University : University name
- SAT : average SAT score of new freshmen
- Top10 : percentage of new freshmen in top 10
- Accept : percentage of applicants accepted
- SFRatio : student-faculty ratio
- Expenses : estimated annual expenses
- Grad: graduation rate

```
#분석에 사용되는 변수들의 범위에 차이가 있다면,
#가장 큰 범위를 갖는 변수가 결과에 가장 큰 영향을 미치게 되기에
#이를 방지하려면 표준화를 통해 변수들의 범위에 차이를 줄여줄 필요
data_univ_new <- scale(data_univ[,-1])
rownames(data_univ_new) <- data_univ[,1]
head(data_univ_new)
```

```
## Harvard 1.2325607 0.7471478 -1.2774171 -0.4228798 0.8413933 1.1349362  
## Princeton 1.0018478 0.7471478 -1.2774171 -1.1604608 0.1963274 0.9141315  
## Yale 1.0018478 0.9529737 -1.0239613 -0.4228798 1.1179293 1.0245339  
## Stanford 0.8634201 0.6956914 -0.9732702 -0.1770194 0.6282200 0.6933268  
## MIT 1.0479904 0.9015172 -0.4663586 -0.6687401 0.5186870 0.4725221  
## Duke 0.4481368 0.6956914 -0.4663586 -0.1770194 0.2909556 0.9141315
```

```
pr_univ <- prcomp(data_univ_new, scale=TRUE)
pc1 <- pr_univ$x[,1]
pc2 <- pr_univ$x[,2]
Mx <- max(abs(pc1))
My <- max(abs(pc2))
plot(pc1,pc2,xlab="PC 1",ylab="PC 2",pch=20,xlim=c(-Mx,Mx),ylim=c(-My,My))
abline(h=0,lty="dotted")
abline(v=0,lty="dotted")
text(x=pc1,y=pc2,labels=rownames(data_univ_new),adj=0,pos=1,cex=0.8)</pre>
```



Contents

K-means clustering

Partitioning Around Medoids (PAM) clustering

Hierarchical clustering

K-means clustering R code I

K-means clustering

```
set.seed(200813)
km2_univ <- kmeans(x=data_univ_new,centers=2,iter.max=1000,nstart=20)</pre>
```

- 1. centers=2는 군집의 개수를 정하는 option이다.
- 2. 원래 K-means clustering algorithm은 군집이 변하지 않을 때까지 iteration을 반복하는 것이지만, iter.max=1000과 같이 최대 iteration 수를 정해두어 무한 루프가 발생하지 않도록 한다.
- 3. 종종 초기값으로 쓰인 군집의 중앙값에 따라 군집화의 결과가 다를 수 있다. nstart=20은 20개의 초기값으로 군집화를 수행한 후에 가장 좋은 결과를 보고하라는 뜻이다.
- 4. 초기 중앙값을 랜덤하게 선택하므로 위의 코드를 수행할 때마다 결과가 다를 수 있다. 이를 방지하기 위해 set.seed 함수를 사용하는 것이 좋다.


K-means clustering R code II

Visualization


```
col_vec <- c("red","blue")
km2_univ$cluster # 각 군집의 labeling
```

##	Harvard	Princeton	Yale	Stanford	MIT
##	2	2	2	2	2
##	Duke	Cal_Tech	Dartmouth	Brown	Johns_Hopkins
##	2	2	2	2	2
##	${\tt U_Chicago}$	U_Penn	Cornell	Northwestern	Columbia
##	2	2	2	2	2
##	NotreDame	U_Virginia	Georgetown	Carnegie_Mellon	U_Michigan
##	2	2	2	2	1
##	<pre>UC_Berkeley</pre>	U_Wisconsin	Penn_State	Purdue	Texas_A&M
##	2	1	1	1	1

K-means clustering R code II.v2



K-means clustering R code III



Calinski-Harabasz Index

Calinski-Harabasz Index


• Calinski-Harabasz Index는 군집화가 얼마나 잘 수행되었는지를 나타내는 지수로서, 다음과 같이 정의된다.

$$CH index = \frac{(n - K)SS_B}{(K - 1)SS_W}$$

- 여기서 n은 관측치의 수, K는 cluster의 수, $SS_B = \sum_{k=1}^K |G_k| \|\bar{x}_k \bar{x}\|^2$ 는 between-cluster variance, $SS_W = \sum_{k=1}^K \sum_{i \in G_k} \|x_i \bar{x}_k\|^2$ 는 within-cluster variance이다. 여기서 \bar{x} 는 전체 자료의 평균, \bar{x}_k 는 k 군집의 평균, 그리고 $|G_k|$ 는 k 군집에 속한 자료의 갯수, $k=1,\cdots,K$.
- Calinski-Harabasz Index가 클수록 within-cluster variance에 비해 between-cluster variance가 크다는 것을 나타내며, 따라서 clustering이 잘 되었음을 나타낸다.


K-means clustering R code IV

Calinski-Harabasz Index



K-means clustering R code V

Visualization



Contents

K-means clustering

Partitioning Around Medoids (PAM) clustering

Hierarchical clustering

PAM algorithm


- 1. Select initial medoids randomly
- 2. Iterate while the cost decreases:
 - (1). In each cluster, make the point that minimizes the sum of distances within the cluster the medoid
 - (2). Reassign each point to the cluster defined by the closest medoid determined in the previous step.

```
# install.packages("cluster")
## 주의 사항
## Do you want to install from sources the package which needs compilation?
## y/n: n
library(cluster)
set.seed(200813)
pam2_univ <- pam(x=data_univ_new,k=2)</pre>
```


• k=2는 cluster의 개수를 지정하는 옵션이다.

PAM clustering R code II

Visualization




PAM clustering R code III




PAM clustering R code V

Silhouette index



PAM clustering R code VI



Contents

K-means clustering

Partitioning Around Medoids (PAM) clustering

4 Hierarchical clustering

Hierarchical clustering

Algorithm

- 1. 한 개의 관측치가 포함된 n개의 군집으로 시작한다.
- 2. i = n, n 1, ..., 2에 대해 다음을 반복한다.
 - 2.1. i개 군집 간의 거리를 계산한다.
 - 2.2. 거리가 가장 가까운 2개의 군집을 합친다.

연결법(linkage): 군집간의 거리를 계산하는 방법

1. complete

$$d(G_1, G_2) = \max_{i \in G_1, j \in G_2} d(x_i, x_j)$$

2. single

$$d(G_1, G_2) = \min_{i \in G_1, j \in G_2} d(x_i, x_j)$$

3. average

$$d(G_1, G_2) = \underset{i \in G_1, j \in G_2}{\text{ave}} d(x_i, x_j)$$

4. centroid

$$d(G_1, G_2) = d(\bar{x}_1, \bar{x}_2), \quad \bar{x}_i = \underset{j \in G_i}{\text{ave }} x_j$$


Hierarchical clustering R code I

Hierarchical clustering

```
dist_univ <- dist(data_univ_new)
hc_complete_univ <- hclust(dist_univ, method="complete")
hc_single_univ <- hclust(dist_univ, method="single")</pre>
```

- dist 함수는 자료들 간의 거리를 계산해주는 함수이다.
- hierarchical clustering을 수행하는 함수는 hcluster이며, method를 통해 연결 방법을 설정해줄 수 있다.
- dendogram은 plot 함수를 이용하여 그릴 수 있다.
- 마지막으로, 군집의 index를 구할 때는 cutree 함수를 이용하면 된다.

Complete Linkage




Check the appropriate number of clusters with the cutree function

```
cutree(hc_complete_univ, k=5) # k= desired number of groups
##
           Harvard
                          Princeton
                                                Yale
                                                             Stanford
                                                                                   MTT
##
                           Cal Tech
                                                                Brown
##
              Duke
                                           Dartmouth
                                                                        Johns Hopkins
##
##
         U Chicago
                             U Penn
                                             Cornell
                                                        Northwestern
                                                                             Columbia
##
##
         NotreDame
                         U Virginia
                                          Georgetown Carnegie_Mellon
                                                                           U Michigan
##
       UC Berkelev
                        U Wisconsin
                                          Penn State
                                                              Purdue
##
                                                                            Texas A&M
##
cutree(hc_complete_univ, k=3) # k= desired number of groups
##
           Harvard
                          Princeton
                                                Yale
                                                             Stanford
                                                                                   MIT
##
                           Cal Tech
                                                                Brown
                                                                        Johns_Hopkins
##
              Duke
                                           Dartmouth
##
                             U Penn
                                            Cornell
                                                        Northwestern
                                                                             Columbia
##
         U Chicago
##
##
         NotreDame
                         U Virginia
                                          Georgetown Carnegie Mellon
                                                                           U Michigan
##
##
       UC Berkeley
                        U Wisconsin
                                          Penn State
                                                               Purdue
                                                                            Texas A&M
##
```


26 / 29

Single Linkage



Hierarchical clustering R code IV

complete



Hierarchical clustering R code V

```
single
```

